Отчет по решению вступительного задания на предстажировку Case Lab ML АО «Гринатом»

Выполнил: Щеглаков Илья Викторович

Адрес эл.почты: boetzvtanke@yandex.ru

2024

Задание:

Дан датасет Large Movie Review Dataset.

1. Необходимо:

   Обучить модель на языке Python для классификации отзывов.

2. Разработать веб-сервис на базе фреймворка Django для ввода отзыва о фильме с автоматическим присвоением рейтинга (от 1 до 10) и статуса комментария (положительный или отрицательный).

3. Развернуть сервис в открытом доступе для оценки работоспособности прототипа.

4. Подготовить отчет о работе с оценкой точности полученного результата на тестовой выборке.

Ход работы:

Датасет представляет из себя набор текстов (отзывов о фильмах), каждому из которых сопоставлено число (оценка). Разработка модели, которая по тексту сможет предсказывать число, является задачей NLP. На мой взгляд, оптимальным решением было бы использовать предобученную сеть, например BERT, и дообучить ее, однако так как задание сформулировано как «обучить модель», то было решено обучать модель с нуля.

В конечном итоге для тестирования были выбраны два пайплайна: TF-IDF векторизация + XGBoost модель; Word2Vec + LSTM.

Забегая вперед, первый вариант оказался предпочтительнее, поэтому рассмотрим его.

Сам датасет содержит не только информацию об оценке отзыва, но и принадлежность классу «положительный» или «отрицательный». Однако, на мой взгляд, предсказывать класс отдельно от оценки большого смысла не имеет, поэтому итоговая классификация будет строиться по предсказанному числу по простому принципу “>=5” или “<5”.

Чтение датасета:

```
folder_path = os.path.join(os.getcwd(), "dataset", "aclImdb", "test", "neg")
data = []
for filename in os.listdir(folder_path):
    score = filename.split('_')[1].replace(".txt", "")
    with open(os.path.join(folder_path, filename), 'r', encoding='utf-8') as
file:
        text = file.read().strip()
    data.append({"text": text, "score": score})
df4 = pd.DataFrame(data)
```

Затем, перед тем, как токенизировать текст, его необходимо предварительно обработать. Для этого я использовал библиотеку nltk и регулярные выражения

```
def preprocess_text(text):
    text = text.lower()
    text = re.sub(r'\d+', '', text)  # Remove numbers
    text = re.sub(r'\W', ' ', text)  # Remove non-word characters
    text = re.sub(r'\s+', ' ', text)  # Remove multiple spaces
    text = ' '.join([word for word in text.split() if word not in stop_words])  #
Remove stopwords
    return text
```

Далее токенизируем тексты:

```
tfidf = TfidfVectorizer(max_features=5000)

X_train_tfidf = tfidf.fit_transform(X_train)
X_test_tfidf = tfidf.transform(X_test)
```

Для обучения модели использовалась библиотека xgboost, так как она проста в настройке и дает SOTA результат на многих задачах.

Параметры модели:

```
xgb_model = XGBRegressor(
    objective='reg:squarederror',
    random_state=6,
    n_estimators=200,
    max_depth=7,
    reg_alpha=10,
    reg_lambda=1,
    learning_rate=0.2,
    colsample_bytree=0.6, subsample=0.7,
)
```

Валидация модели:

```
y_pred = xgb_model.predict(X_test_tfidf)
correct = 0
total = 0
mae = mean_absolute_error(y_test, y_pred)

predicted = (y_pred >= 5)
labels = y_test.apply(lambda p: 1 if p>=5 else 0)
correct += (predicted == labels).sum().item()
total += labels.shape[0]
print(f"Mean Abs Error: {mae}  Accuracy: {correct / total}")
```

На тестовом наборе данных (случайная выборка в 50% от общего датасета) модель показала следующий результат:

Mean Abs Error: 1.8266662257038522
Accuracy: 0.8326

Для улучшения финальной модели имеет смысл обучить ее на всех имеющихся данных.

Помимо этого, была реализована и протестирована LSTM модель, однако она показывает схожие результаты метрик при гораздо больших затратах времени на обучение и вывод результата, поэтому целесообразнее использовать первую модель.

Также, для работы с полученной моделью был сделан веб интерфейс на основе фреймворка Django.

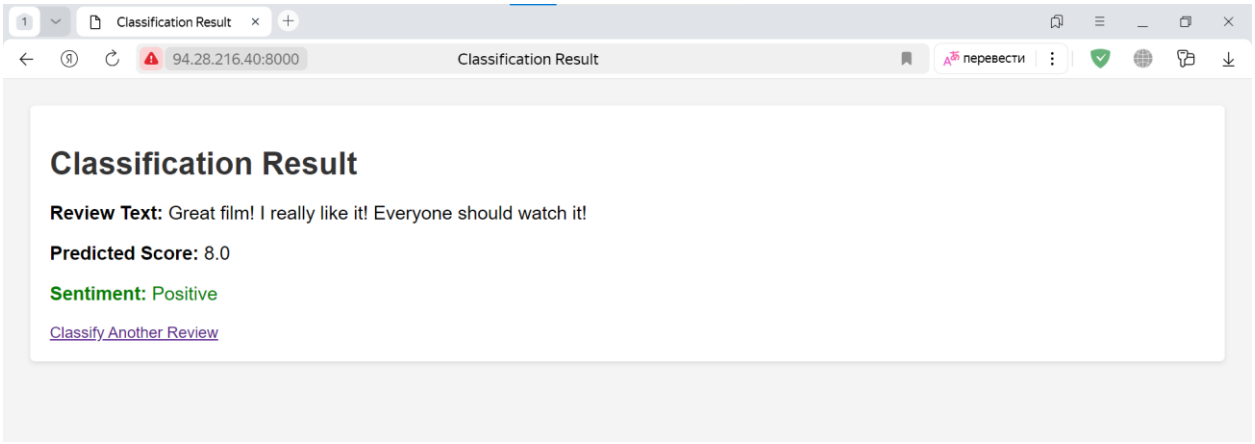

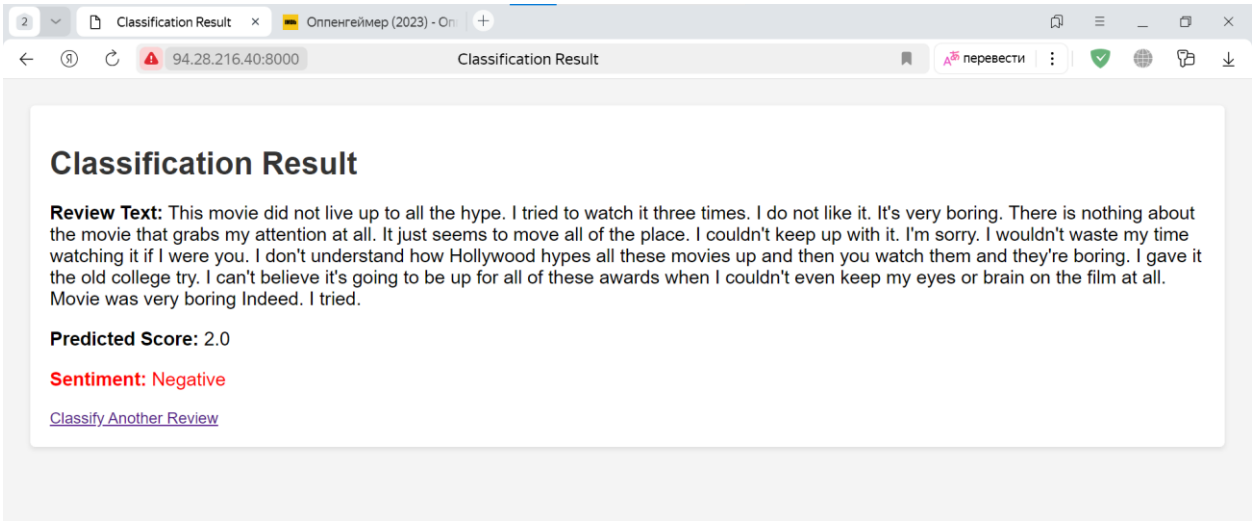

Итог

В результате работы была обучена модель классификации отзывов фильмов на основе их текста, предсказывающая оценку и класс. Был разработан веб-сервис, позволяющий удобно взаимодействовать с полученной моделью.

Модель имеет следующие значения метрик на тестовой выборке:

Mean Abs Error: 1.8266662257038522
Accuracy: 0.8326

Что, учитывая специфику области ее работы, можно считать удовлетворительным результатом.